

Vergelijkingschecklist: onze simulator naast Sama's R-code

Doel: de verschillen tussen beide implementaties systematisch vinden, zodat we weten of afwijkende resultaten uit de **data-generatie** of uit het **modelfitten** komen.

Onze kolom is ingevuld uit de code (`sim.py` , `metc_simulation_report.py` , `dlt_mitigation_analysis.py`). De rechterkolom is voor Sama's implementatie.

Volgorde is op afnemende verwachte impact — bovenaan staan de punten die een groot verschil in MTD-accuracy kunnen verklaren.

Al gevonden, vóór het overleg

✓ Onze MTD-definitie en scenario's kloppen met die van Sama

De ware MTD op haar slides is te reproduceren als "*hoogste dosis met ware acute toxiciteit $\leq$ target*", in **1-based** dosisnummering:

SCENARIO	WARE ACUTE KANSEN	ONZE MTD (0-BASED)	SAMA'S NOTATIE (1-BASED)
Acute low	0.01 0.02 0.06 0.10 0.15	L4	5
Acute middle	0.01 0.04 0.12 0.17 0.27	L3	4
Acute high	0.01 0.05 0.15 0.22 0.30	L2	3
Acute steep	0.01 0.02 0.08 0.24 0.34	L2	3
Acute shallow	0.10 0.13 0.15 0.18 0.24	L3	4

Haar `MTD_late = 5` in alle scenario's klopt ook: alle subacute kansen liggen onder 0.33.

Actie: geen — maar spreek expliciet af welke nummering we in verslaglegging gebruiken. `L2` bij ons is `dosis 3` bij haar. Eén off-by-one in een tabel is genoeg om een hele discussie te vertroebelen.

⚠ Onze subacute prior wijkt af van wat per mail is doorgegeven

	L0	L1	L2	L3	L4
Mail van 8 juli aan Sama	0.010	0.036	0.084	0.157	0.250
Onze code	0.012	0.036	0.084	0.157	0.250

Actie: uitzoeken welke de bedoelde is en één van de twee corrigeren. Het effect is klein (het gaat om het laagste niveau), maar het is een echte inconsistentie tussen wat wij simuleren en wat Sama gebruikt.

1. Data-generatie — hier verwachten we de grootste verschillen

1.1 Tijd tot DLT

	ONZE CODE	SAMA
Acute (tox1)	Uniform over het hele acute venster	Log-normaal (per haar mail 31 juli)
Subacute (tox2)	Uniform over het subacute venster	Log-normaal

Waarom het uitmaakt: alleen via de TITE-gewichten. Een log-normale verdeling concentreert events eerder of later in het venster, waardoor het partiële gewicht op het beslismoment anders uitvalt. Effect op MTD-accuracy is waarschijnlijk beperkt, op trialduur groter.

Vraag aan Sama: welke parameters (meanlog/sdlog), en gedefinieerd vanaf welk moment — inclusie, RT-start, of RT-einde?

1.2 Tijd tot operatie en uitstel van de OK

	ONZE CODE	SAMA
Vindt OK plaats?	Bernoulli met $p = 0.80$	?
Tijd RT-einde → OK	Vaste constante van 42 dagen	Log-normaal
Kans op uitstel	Niet gemodelleerd	Aparte kans + verdeling van de uitstelduur

Waarom het uitmaakt: dit is het duidelijkste verschil dat we kennen. Bij ons varieert de OK-datum helemaal niet, dus het subacute venster opent bij iedere patiënt op precies dezelfde relatieve dag. Bij Sama varieert dat, wat de weging van partiële subacute follow-up direct beïnvloedt.

Actie aan onze kant: overwegen dit toe te voegen zodra we haar parametrisatie hebben.

1.3 Accrual

	ONZE CODE	SAMA
Proces	Poisson (exponentiële tussenaankomsttijden)	?
Tempo	0.75/maand = 1 patiënt per 4 weken	slides: 1 per 4 weken; Koen vroeg om 1.5/maand

Actie: één tempo afspreken vóór de definitieve run. 1.5/maand $\approx$ 1 per 3 weken.

2. Beslisregels — hier verwachten we het grootste effect op MTD-accuracy

2.1 Dosistoewijzing tijdens de trial

	ONZE CODE	SAMA
EWOC aan	Hoogste dosis waar $P(\text{tox} > \text{target}) < \alpha$ voor beide eindpunten	?
EWOC uit	Dosis met posterior gemiddelde dichtst bij target (klassieke CRM)	Hoogste dosis met puntschatting onder target (mail 8 juli)
Dose skipping	Verboden: <code>max_step = 1</code> én niet hoger dan <code>hoogste_geprobeerd + 1</code>	verboden

Dit is vermoedelijk de belangrijkste bron van verschil. Onze "EWOC uit" is een ander algoritme dan haar "EWOC uit". Hare is strenger: één DLT die de puntschatting van een hoog niveau net over de target duwt sluit dat niveau uit, terwijl onze argmin-regel dat niveau nog kan kiezen.

Vraag aan Sama: gebruikt ze het posterior gemiddelde, de posterior mediaan, of een plug-in schatter op de posterior mean van de parameter? Dat laatste geeft merkbaar andere waarden.

2.2 Finale MTD-selectie

	ONZE CODE	SAMA
Regel	Zelfde als toewijzing, plus <code>restrict_to_tried = True</code>	?
Alleen uit geprobeerde doses?	Ja	?

Waarom het uitmaakt: als zij ook niet-geprobeerde doses als MTD kan selecteren, is haar accuracy in het Acute low scenario structureel hoger dan de onze.

2.3 Burn-in

	ONZE CODE	SAMA
Definitie	Escaleer 1 niveau per cohort tot de eerste waargenomen tox1	idem
Strikte follow-up-eis	Optioneel: escaleren mag pas als $\geq$ cohortgrootte patiënten volledige acute FU zonder DLT hebben	?

Let op: in de simulaties met de DLT bij initialisatie is burn-in per definitie meteen voorbij, dus dit verklaart hier niets. Wel relevant voor de eerdere vergelijkingen.

3. Model en posterior

	ONZE CODE	SAMA
Modelvorm	Empirisch / power: $p_d = \text{skeleton}_d^{\exp(\theta)}$	? (<code>dfcrm</code> default is empiric)
Prior op θ	Normaal, gemiddelde 0, $\sigma = 1.0$	?
Integratie	Gauss-Hermite, 61 knopen (41 in het METC-rapport)	? (<code>dfcrm</code> gebruikt numerieke integratie)
Acute skeleton	0.004 0.021 0.066 0.150 0.266	idem, per mail
Subacute skeleton	0.012 0.036 0.084 0.157 0.250	0.010 ... — zie inconsistentie hierboven
Skeleton-herkomst	Exacte getallen, niet uit halfwidth herleid	Koen adviseerde exacte getallen

Waarom het uitmaakt: σ bepaalt hoe hard het model de skeleton loslaat. Als haar σ afwijkt, verschuiven alle posteriors. Dit is het meest waarschijnlijke "fit"-verschil naast de beslisregel.

Vraag aan Sama: welke waarde voor σ , en of dat de pakket-default is of een bewuste keuze. In `dfcrm` heet deze parameter `scale`; de default daar is níet 1.0, dus als zij de default heeft laten staan wijkt haar prior af van de onze. Belangrijk om expliciet te maken of we het over de standaarddeviatie of de variantie hebben — dat is een klassieke bron van een factor-verschil.

4. Follow-up vensters en TITE-weging

	ONZE CODE	SAMA
Inclusie → RT-start	21 dagen	?
Duur RT	14 dagen	?
RT-einde → OK	42 dagen (vast)	log-normaal
Acuut venster	56 dagen, startend bij RT-start	?
Subacuut venster	30 dagen, startend bij de OK	?
Gewichtsfunctie	Lineair: verstreken tijd / vensterlengte, afgekapt op 1	? (standaard TITE is ook lineair)
Waargenomen event	Gewicht 1	idem verwacht
Nog niet in venster	Gewicht 0	?

Op te merken: bij ons eindigt het acute venster **exact op de OK-datum** ($21 + 14 + 42 = 77$ dagen na inclusie = RT-start + 56). Dat is geen toeval maar een gevolg van `tox1_win = rt_dur + rt_to_surg`. Als Sama de OK-datum laat variëren, kan haar acute venster niet ook automatisch op de OK eindigen — dan is dat een structureel verschil in de definitie van het acute venster.

Vraag aan Sama: is haar acute venster een vaste kalenderduur, of loopt het tot de OK?

5. Beslismoment en timing

	ONZE CODE	SAMA
Wanneer wordt de dosis bepaald?	Op het moment dat de laatste patiënt van het cohort arriveert ; geen wachttijd tussen cohorten	?
Cohortgrootte	3	3
Partiële data gebruikt?	Ja, dat is het punt van TITE	ja

Waarom het uitmaakt: dit bepaalt hoeveel follow-up er per beslissing beschikbaar is, en daarmee zowel de trialduur als de kwaliteit van elke beslissing. Als zij wél wacht (bijvoorbeeld tot een minimum aan follow-up), verklaart dat een deel van het duurverschil.

6. Initialisatie met de bestaande zes patiënten

	ONZE CODE	SAMA
Aantal	6 op L1 (dosis 2 in haar nummering)	6
Acute DLT's	1, bij de laatste van de zes	1
Tijdstip van de DLT	Op het einde van het (al verstreken) follow-up venster, dus vanaf dag 0 waargenomen	?
Gewicht in de likelihood	Volledig (1.0), tenzij hist_weight anders staat	?
OK-status	Getrokken uit $p = 0.80$	?
Subacute DLT's	0 voor alle zes	?
Tellen ze mee in max_n?	Ja — 30 totaal betekent 24 nieuwe patiënten	?

Dit laatste punt is belangrijk: als haar 30 patiënten **naast** de zes bestaande komen, heeft haar trial 6 patiënten meer om mee te escaleren. Dat alleen al kan een groot deel van het accuracy-verschil in Acute low verklaren.

7. Het 6+3 design — grootste onverklaarde gat

In Acute low vinden wij **3.2%** correcte MTD-selectie voor 6+3; haar slide toont **32.3%**. Twee concrete hypothesen, beide te testen:

Hypothese A — andere initialisatie. Onze run_tite_6plus3 kent geen voorgeschiedenis: die start schoon op L2 met 30 patiënten. Haar 6+3 in deze run heeft mogelijk wél de zes patiënten met de DLT. Onze vergelijking is dus niet één-op-één.

Hypothese B — onze 6+3-regels zijn strenger. Onze implementatie eist voor escalatie:

- minstens 6 patiënten **én** 6 patiënten met een OK op het niveau (bij $p = 0.80$ betekent dat gemiddeld ~ 7.5 inclusies per niveau);
- 0 acute DLT's in 6, of ≤ 1 in 9;
- ≤ 1 subacute DLT in 6, of ≤ 3 in 9;
- volledige follow-up van het hele cohort vóór de beslissing, met "bridging"-patiënten op een lager niveau tijdens het wachten — die verbruiken wél sample size.

Een klassiek 6+3 zonder OK-evaluabiliteitseis en zonder bridging klimt binnen 30 patiënten veel verder. **Actie:** vraag Sama's exacte escalatie- en stopregels op en zet ze naast bovenstaande lijst.

8. Uitkomstmaten — appels met appels

	ONZE DEFINITIE	SAMA
Correcte MTD	Geselecteerde dosis == hoogste met ware tox $\leq$ target	idem (geverifieerd)
Te hoge MTD	Geselecteerd > ware MTD	?
Aantal DLT's	Alleen nieuwe patiënten, exclusief de zes bestaande	?
Trialduur	Aantal nieuwe patiënten $\times$ 4 weken	?
Trialduur bij ons	96 weken (vast: er is geen early stopping, dus altijd max_n)	slides: 30 weken in Acute low

Het duurverschil van 96 tegen 30 weken is te groot om alleen uit accrual te komen. Waarschijnlijke oorzaak: haar design stopt vroeg (early stopping), of zij rekent de duur tot de laatste **beslissing** in plaats van tot het einde van alle follow-up. Bij ons staat early stopping uit ($p_{\text{stop}} = 1.0$).

Vraag aan Sama: zit er een stopregel in, en vanaf welk moment tot welk moment wordt de duur gemeten?

Praktische aanpak voor het overleg

1. **Wissel eerst één generating file uit.** Wij hebben er al één klaarstaan (`trial_export/`): één trial, 30 patiënten, met per patiënt dosis, acute DLT + dag, OK + dag, subacute DLT + dag. Laat Sama die door haar model halen.
2. **Vergelijk cohort voor cohort, niet alleen de eindconclusie.** Onze `tite_crm_output_trial1.csv` bevat per beslistmoment de TITE-gewichten, de posterior gemiddelden per dosis en de gekozen dosis. Wijkt de eerste beslissing al af, dan zit het in de weging of de prior; wijkt pas een latere af, dan in de beslisregel.
3. **Zet vervolgens σ en de beslisregel gelijk** en kijk of de verschillen verdwijnen. Dat isoleert het effect van de data-generatie.
4. **Laat het 6+3 apart lopen.** Dat is een eigen vergelijking met een eigen oorzaak, en het vertroebelt de CRM-discussie als we het erbij houden.